

Детектирование аномалий во временных рядах методами больших языковых моделей

Студент: Петров Олег
Руководитель: Гуцин Михаил
НУЛ методов анализа больших данных

Laboratory of Methods
for Big Data Analysis



Введение

Актуальность:

- Временные ряды: промышленность, финансы, медицина, IT и др.
- Обнаружение аномалий → безопасность и надёжность систем

Основные проблемы:

- Традиционные методы: слишком простые, немногомерны
- Классика ML: временная структура
- RNN, Transformer: проблема переноса знаний (обобщение)

Современные тенденции

Недавние прорывы в области LLM вдохновили создание **фундаментальных** моделей для временных рядов: обучение на больших кросс-доменных корпусах + zero-/few-shot инференс.

Яркие представители:

- MOMENT (2024): универсальность, реконструкция, собранный датасет
- TimeRCD (2025): специализированность, реконструкция + детекция аномалий, собственный синтетический корпус

Проблематика и цель

Проблема: представление многоканальных рядов на входе трансформера

- Разные модели – разные эвристики
- Выбор часто обусловлен эффективностью, а не точностью
- Систематического сравнения стратегий до сих пор не проводилось

Цель:

- Исследование влияния способов разных стратегий на качество обнаружения аномалий
- Разработка практических рекомендаций по выбору эвристик

Три стратегии представления многомерных данных

Стратегия	Принцип	Токен	Форма
Независимая	Каждый канал отдельно (как независимый ряд)	Одноканальный патч	$(B \times D, N, P)$
Вытягивание	Объединение осей патчей и каналов	Один патч, привязанный к конкретному каналу	$(B, N \times D, P)$
Смешивание* (собств.)	Слияние осей каналов и времени в единое представление с последующим обучаемым восстановлением	Общий патч для всех каналов (единое представление)	$(B, N, D \times P)$

Обозначения: B (размер пакета), D (число каналов), N (число патчей), P (длина патча)

*: все каналы «смешаны» внутри токена, но канальная информация восстанавливается через обучаемые эмбеддинги на выходе трансформера

Три стратегии: структурно

Стратегия	Токенизация ($D=3$, $B=1$)
Независимая	$[ch1_pat1, \dots, ch1_patN], [ch2_pat1, \dots, ch2_patN], [ch3_pat1, \dots, ch3_patN]$ D списков, по N патчей (токенов) размера P в каждом списке
Вытягивание	$[ch1_pat1, ch2_pat1, ch3_pat1, \dots, ch1_patN, ch2_patN, ch3_patN]$ Список из $N \times D$ патчей (токенов) размера P
Смешивание (собств.)	$[pat1, pat2, \dots, patN]$ N токенов размера $D \times P$

1. Эмбеддинг токена в единую последнюю размерность (512)
2. Маскирование и позиционное кодирование (RoPE)
3. Скармливание трансформеру
4. Линейная проекция
5. Для смешивания: аддитивный эмбеддинг для различения каналов

Методология

Базовый подход: **реконструктивный**

1. Учимся восстанавливать нормальные данные
2. Аномалия = высокая ошибка реконструкции
3. Наилучший квантильный порог по ошибке реконструкции


Решение	Причина
Обучение с нуля на каждом датасете	Исключаем влияние предобучения (zero-shot)
Единые гиперпараметры и архитектура Единый размер данных	Честное сравнение
Поточечная корректировка (point adjustment)	Промышленный стандарт

Архитектура

- Трансформенный кодировщик
- Any-Variate Attention для учета внутри- и межканальных взаимодействий токенов
- RoPE для всех стратегий
- Отказ от головы детекции (неэффективно)

Значение	Описание
512	Ширина слоя внимания
256	Размерность проекции после кодировщика и реконструкции
8	Количество слоев внимания
8	Количество голов внимания
16	Размер временного патча (окна)

37 миллионов обучаемых параметров



Данные

Используем синтетические данные, разделенные по типам аномалий:

		Размеры выборок				Доля аномальности	
Название	Тип аномалии	Обучение	Валидация	Тест	D	Валидация	Тест
Global	точечная	20K	10K	20K	5	6%	6%
Contextual	точечная	20K	10K	20K	5	6%	6%
Seasonal	паттерн	20K	10K	20K	5	6%	6%
Shapelet	паттерн	20K	10K	20K	5	5%	5%
Trend	паттерн	20K	10K	20K	5	6%	6%

Метрики:

- Реконструкция: RMSE, MAE
- Детекция: AUC-ROC, Precision, Recall, F1

Результаты: по наборам данных

Ключевые наблюдения:

- Смешивание стабильно лучше или сравнимо на всех наборах
- Shapelet – самый тяжелый тип аномалий для всех стратегий (самый низкий Recall)
- Global – самый простой
- Слабая связь между ошибкой реконструкции и качеством детекции

Независимая

Метрика	Global	Contextual	Seasonal	Shapelet	Trend	Среднее
RMSE	0.1649	0.1289	0.3438	0.1315	0.2867	0.2112
MAE	0.1029	0.0940	0.2691	0.1002	0.1851	0.1503
AUC-ROC	0.9777	0.8770	0.8098	0.7469	0.8777	0.8578
F1	0.9032	0.6201	0.5767	0.4094	0.7230	0.6465
Precision	0.9700	0.7550	0.8790	0.8700	0.8760	0.9060
Recall	0.8449	0.5261	0.4291	0.2677	0.6015	0.5339

Вытягивание

Метрика	Global	Contextual	Seasonal	Shapelet	Trend	Среднее
RMSE	0.1731	0.1419	0.2090	0.1390	0.2244	0.1775
MAE	0.1112	0.1043	0.1275	0.1068	0.1368	0.1173
AUC-ROC	0.9870	0.8682	0.8922	0.7281	0.8570	0.8665
F1	0.8770	0.5951	0.4975	0.3690	0.4598	0.5597
Precision	0.9446	0.8612	0.9579	0.8507	0.7076	0.8644
Recall	0.8185	0.4546	0.3360	0.2356	0.3405	0.4370

Смешивание

Метрика	Global	Contextual	Seasonal	Shapelet	Trend	Среднее
RMSE	0.1565	0.1164	0.1869	0.1155	0.3523	0.1855
MAE	0.0950	0.0825	0.0980	0.0860	0.1252	0.0973
AUC-ROC	0.9770	0.8904	0.9341	0.8051	0.9586	0.9130
F1	0.9218	0.7166	0.7619	0.4188	0.7387	0.7096
Precision	0.9900	0.8725	1.0000	0.8900	0.9800	0.9465
Recall	0.8624	0.6080	0.6154	0.2738	0.5927	0.5905

Результаты: средние

- Разработанная нами стратегия смешивания показала **наилучшие** средние результаты по всем наборам данных
- Вытягивание (TimeRCD) показывает **наихудшие** результаты при обучении с нуля
- Консервативное принятие решений: низкая полнота, высокая точность

Метрика	Вытягивание	Независимая	Смешивание
RMSE	0.1775	0.2112	0.1855
MAE	0.1173	0.1503	0.0973
AUC-ROC	0.8665	0.8578	0.9130
F1	0.5597	0.6465	0.7096
Precision	0.8644	0.9060	0.9465
Recall	0.4370	0.5339	0.5905

Почему вытягивание хуже?

Возможная проблема: неподходящий экспериментальный протокол

Условие	Методология TimeRCD	Наша методология
Данные	Сотни тысяч / Миллионы Собственный синтетический корпус с разметкой	20 000 для каждого набора Без разметки
Режим	Предобучение + zero-shot / fine-tuning	Обучения с нуля отдельно на каждом датасете
Функция потерь	Реконструкция + классификация	Только реконструкция
Результат (F1)	state-of-the-art	Наихудший по всем наборам

Вытягивание — потенциально мощный подход, но он не предназначен для обучения с нуля на ограниченных данных.

Практические рекомендации

Сценарий	Рекомендация	Объяснение
Сильные межканальные корреляции, высокая полнота критична	Смешивание	Лучший баланс, особенно по Recall
Много каналов, слабые корреляции	Независимая	Линейно масштабируемо
Ограниченные вычислительные ресурсы	Независимая или смешивание	Вытягивание требует больше токенов ($N \times D$)
Обучение с нуля на небольших данных	Независимая или смешивание	Вытягивание демонстрирует наихудшие результаты
Требуется фундаментальность (переменное D)	Независимая или вытягивание	Смешивание привязано к конкретному D

Заключение

1. Предложена **новая** стратегия смешивания с аддитивными канальными представлениями
 - а. Показало **наилучшие** усредненные метрики
2. Проведено **первое** систематическое сравнение трёх стратегий *в единой методологии*
3. **Выявлено**, что вытягивание (TimeRCD) неэффективно *при обучении с нуля*
 - а. В частности, это касается всей методологии TimeRCD
4. Сформулированы **практические рекомендации** по выбору стратегии
5. **Отмечена** проблема низкой корреляции ошибки реконструкции с качеством обнаружения аномалий – фундаментальное ограничение



Дальнейшие направления

Ограничения:



- Только синтетические данные (5 небольших наборов)
- Один GPU (GTX 1050), ограниченная сетка подбора гиперпараметров
- Обучение с нуля, без масштабного предобучения

Перспективы:



- Эксперименты на реальных бенчмарках (SWaT, SMD, MSL, WADI)
- Методология TimeRCD
- Адаптация смешивания для фундаментальности (произвольное D)
- Модернизация функции потерь: целевая детекция на основе гибридных логитов реконструкции и классификации, а не реконструкция + классификация (как в TimeRCD)

Спасибо за внимание!



Пример визуализации: Seasonal









Пример визуализации: Shapelet



Пример визуализации: Trend



Пример визуализации: Contextual



Пример визуализации: Global

